Projektrapport

Datavisualization - Design and Construction, 7,5 hp
HT 19, period 1
Visualisering av källkod

av

Thomas Lundgren
900802-1835
thomaslundgren@live.com

Niklas Nordgren
901010-5758

n_nordgren@hotmail.com

Hanna Medén 960214-0965 <u>hannameden@hotmail.com</u>

Institutionen för matematik, natur- och datavetenskap Högskolan i Gävle

S-801 76 Gävle, Sweden

Innehållsförteckning

1	Inledning	1
1.1	Bakgrund	1
1.2	Syfte	1
1.3	Frågeställning	1
2	Metod	2
2.1	Bidragshistorik till Git-repository	2
2.1	.1 Importera genererade data till Matlab	
	.2 Diagram över de bidragsgivare som bidragit mest	
2.2	Tillämpande av LOC på olika kodbaser	5
2.3	Riktade grafer	6
3	Resultat	11
3.1	Bidragshistorik till Git-repository	11
3.1	.1 Diagram över de bidragsgivare som bidragit mest	11
	.2 Utskrift av antalet bidragsgivare, antalet bidrag och bidrag per	
bidı	ragsgivare	11
3.1	.3 Visualisering av antalet bidrag över tid	12
3.2	Tillämpande av LOC på olika kodbaser	13
3.2	.1 Diagram över ett ramverks beståndsdelar (Programmeringsspråk)	13
3.2	.2 Diagram över ramverkens beståndsdelar (Antal filer)	14
3.2	.3 Diagram över ramverkens beståndsdelar (Antal rader kod)	
3.3	Riktade grafer	15
4	Diskussion	17
4.1	Bidragshistorik till Git-repository	17
4.2	Tillämpande av LOC på olika kodbaser	
4.3	Riktade grafer	
5	Referenser	

1 Inledning

1.1 Bakgrund

Källkod bör vara enkel att upprätthålla för att minimera tidsåtgången av mjukvaruutveckling. Faktorerna som påverkar detta är bland annat kodbasens klassrelationer, komplexitet och struktur.

Visualiseringar av källkod ger utvecklare och andra intressenter en bättre överblick över källkodens skick, samt om det förekommer brister som måste åtgärdas.

1.2 Syfte

Syftet med detta projekt var att undersöka möjligheterna att visualisera källkod i dataanalysverktyget Matlab.

1.3 Frågeställning

För att avgränsa arbetet valdes tre olika aspekter av en kodbas som skulle visualiseras:

- Relationer mellan klasser i en Java-kodbas.
- Bidragen (eng. commits) till ett Git-repository över tid.
- Storleken hos en kodbas.

Avgränsningen resulterade i följande frågeställningar:

- Hur visualiseras relationer mellan klasser i Java-källkod med användning av en riktad graf på bästa sätt?
- Hur visualiseras relationer mellan klasser i Java-källkod med användning av en grannmatris (eng. adjacency matrix) på bästa sätt?
- Hur visualiseras bidragen till en kodbas över tid med hjälp av bidragshistorik framtaget med versionshanteringssystemet Git på bästa sätt?
- Hur visualiseras storleken hos en kodbas och hur jämförs den med andra kodbasers storlek på bästa sätt?

2 Metod

2.1 Bidragshistorik till Git-repository

2.1.1 Importera genererade data till Matlab

Git lagrar all bidragshistorik förknippat med ett repository i loggfiler. För att generera data över bidragshistoriken användes kommandot git log i Git Bash. Det repository som användes var CSS-ramverket Bootstrap. Resultatet skrevs till en textfil med tabbseparerade värden (TSV-fil). Figur 1 visar innehållet i textfilen.

```
Merge branch 'dev' of <a href="https://github.com/ThomasLundgren/datavis-projekt">https://github.com/ThomasLundgren/datavis-projekt</a> into dev Added code to callgraph.mlx to create adjacency matrix

Merge branch 'dev' of <a href="https://github.com/ThomasLundgren/datavis-projekt">https://github.com/ThomasLundgren/datavis-projekt</a> into dev
1 054ee07 Thomas Lundgren Fri Oct 25 11:12:50 2019
     f5756e3 Thomas Lundgren Fri Oct 25 11:12:45 2019
b96a81d NiklasNordgren Fri Oct 25 08:55:18 2019
      3be2106 NiklasNordgren Fri Oct 25 08:55:04 2019
6c3ed80 Thomas Lundgren Fri Oct 25 08:53:13 2019
                                                                                                     Create get_edges_output.txt
Remove irrelevant files
Merge branch 'dev' of https://github.com/ThomasLundgren/datavis-projekt into dev
   cc23a02 NiklasNordgren Fri Oct 25 08:51:09 2019
Oeb4e0e NiklasNordgren Fri Oct 25 08:51:05 2019
                                                                                                      Loc grejjer
                                                                                                     Update thomas.mlx
Fixed bug in get_edges.jar
  8 Sceb9a4 Thomas Lundgren Thu Oct 24 07:56:09 2019
       e753057 Thomas Lundgren Tue Oct 22 17:51:19 2019
10 1e83244 Thomas Lundgren Tue Oct 22 17:15:14 2019 11 76259ef Thomas Lundgren Tue Oct 22 17:13:36 2019
                                                                                                      Create get_edges_output.txt
Update get_edges.jar
                                                                                                     Create get_edges.jar
Added regex matching txt-doc, change name of mlx file
Fix bootstrap path in SourceWiz
     5c12082 Thomas Lundgren Tue Oct 22 13:02:28 2019 82aa752 Thomas Lundgren Tue Oct 22 10:58:59 2019
       f6aee94 Thomas Lundgren Wed Oct 16 15:14:38 2019
15 472e03d Thomas Lundgren Wed Oct 16 14:57:58 2019
```

Figur 1: Resultatet av att köra kommandot git Log i Git bash.

Innehållet i textfilen manipulerades genom Notepad++:s funktion "hitta och ersätt". Ett reguljärt uttryck användes som ersatte veckodag, datum, klockslag och kolontecken med ett blanksteg i kolumnen som innehåller datum, se Figur 2.

```
Thomas Lundgren Oct 2019
                                                  Merge branch 'dev' of https//gib.com/ThomasLundgren/datavis-projekt into dev
1 054ee
     f5756e Thomas Lundgren Oct 2019
                                                 Added code to callgraph.mlx to create adjacency matrix
    bad NiklasNordgren Oct 2019 Merge branch 'dev' of https//gib.com/ThomasLundgren/datavis-projekt into dev
     be2106 NiklasNordgren
                                   Oct 2019
                                                 Create get_edges_output.txt
    ced Thomas Lundgren Oct 2019 Remove irrelevant files
     cca NiklasNordgren
                              Oct 2019
                                             Merge branch 'dev' of https//gib.com/ThomasLundgren/datavis-projekt into dev
    ebee NiklasNordgren Oct 2019 Loc grejjer
ceba Thomas Lundgren Oct 2019 Update thomas.mlx
e753057 Thomas Lundgren Oct 2019 Fixed bug in get_edges.jar
e83244 Thomas Lundgren Oct 2019 Create get_edges_output.txt
    76259ef Thomas Lundgren Oct 2019 Update get_edges.jar
c12082 Thomas Lundgren Oct 2019 Create get_edges.jar
              Thomas Lundgren Oct 2019 Added regex matching txt-doc, change name of mlx file Thomas Lundgren Oct 2019 Fix bootstrap path in SourceWiz
              Thomas Lundgren Oct 2019
    faee
15 472ed Thomas Lundgren Oct 2019 Created SourceWiz.mlx
```

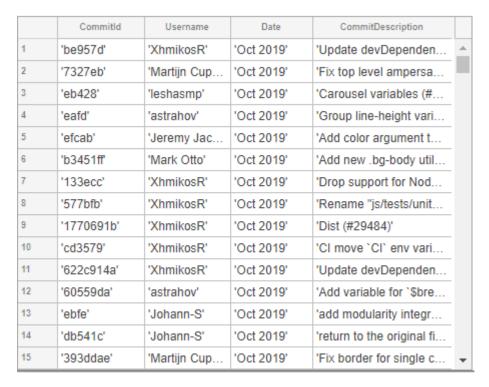
Figur 2: TSV-filen efter att funktionen "hitta och ersätt" har använts.

TSV-filen öppnades sedan i Microsoft Excel och sparades i xlsx-format (Exceldokument-format), se Figur 3.

1	Α	В	С	D	E	F	G	Н	1	L
1	be957d	XhmikosR	Oct 2019	Update d	evDepende	encies. (#2	9508)			
2	7327eb	Martijn Cuppens	Oct 2019	Fix top le	vel ampers	and (#295	18)			
3	eb428	leshasmp	Oct 2019	Carousel	variables (#29493)				
4	eafd	astrahov	Oct 2019	Group lin	e-height va	ariables (#	29466)			
5	efcab	Jeremy Jackson	Oct 2019	Add colo	r argument	to button	mixins (#2	9444)		
6	b3451ff	Mark Otto	Oct 2019	Add new	.bg-body u	tility class	(#29511)			
7	133ecc	XhmikosR	Oct 2019	Drop sup	port for No	de.js . (#29	9496)			
8	577bfb	XhmikosR	Oct 2019	Rename	"js/tests/ur	nits" to "js	tests/unit/	". (#29503)		
9	1770691b	XhmikosR	Oct 2019	Dist (#29	484)					
10	cd3579	XhmikosR	Oct 2019	CI move	'CI' env vari	iable to the	e root of th	e workflov	v. (#29499)
11	622c914a	XhmikosR	Oct 2019	Update d	evDepende	encies. (#2	9447)			
12	60559da	astrahov	Oct 2019	Add varia	able for `\$bi	readcrumb	-font-size`	(#29467)		
13	ebfe	Johann-S	Oct 2019	add mod	ularity inte	gration tes	it			
14	db541c	Johann-S	Oct 2019	return to	the origina	I file struc	ture to avo	id breaking	g modular	ity
15	393ddae	Martijn Cuppens	Oct 2019	Fix borde	er for single	card in ac	cordion (#2	9453)		

Figur 3: TSV-filen importerad till Microsoft Excel.

Innehållet i Excel-filen importerades slutligen till Matlab genom funktionen readtable(). Resultatet redovisas i Figur 4.



Figur 4: Data importerat till tabell i Matlab genom funktionen readtable().

2.1.2 Diagram över de bidragsgivare som bidragit mest

Koden för att skapa ett diagram över de bidragsgivare som gjort flest bidrag till Bootstrap:s repository redovisas i Figur 5.

```
[sortedCommits, newIndices] = sort(commitsPerContr, "descend");
8
9
       sortedContributors = contributors(newIndices);
10
       x = 10
                              ;
11
       x = round(x);
       topxUsers = sortedContributors(1:x);
       sortedContributors = categorical(topxUsers, topxUsers);
       sortedCommits = sortedCommits(1:x);
17
       bar(sortedContributors, sortedCommits);
18
       s = strcat('Top ', num2str(x), ' contributors');
19
       title(s);
```

Figur 5: Koden för att skapa ett stapeldiagram över de användare som bidragit mest.

Koden grupperar antalet bidrag efter bidragsgivare med funktionen histcounts(), sorterar efter antalet bidrag i fallande ordning och skapar ett stapeldiagram med funktionen bar().

1.1.2 Utskrift av antalet bidragsgivare, antalet bidrag och bidrag per bidragsgivare

Programmet skriver ut antalet bidragsgivare, antalet bidrag och bidrag per bidragsgivare (Figur 6).

```
numContributors = length(contributors);
numCommits = length(gitHistoryTable.CommitId);
avgCommits = numCommits/numContributors;
disp(['Number of contributors: ', num2str(numContributors)])
disp(['Number of commits: ', num2str(numCommits)])
disp(['Average commits per contributor: ', num2str(avgCommits)])
```

Figur 6: Koden för att skriva ut antalet bidragsgivare, antalet bidrag och bidrag per bidragsgivare.

1.1.3 Visualisering av antalet bidrag över tid

För att visualisera antalet bidrag till Bootstrap:s kodbas över tid skapades ett linjediagram. Figur 7 visar koden som producerar diagrammet.

```
months = categorical(gitHistoryTable.Date);
27
       [commitsPerMonth, months] = histcounts(months);
28
       monthDates = datetime(months);
       plot(monthDates, commitsPerMonth, 'LineWidth', 2);
29
30
       title('Commits over time');
31
32
       grid on;
       xlabel('Year');
33
       ylabel('Number of commits');
34
```

Figur 7: Koden för att visualisera bidragen till kodbasen över tid.

2.2 Tillämpande av LOC på olika kodbaser

Den öppna programvaran LOC användes på sex olika kodbaser för att få ut visualiseringsdata. Samtliga kodbaser som verktyget användes på är likartade i det avseende att de alla är ramverk eller bibliotek för webbutveckling.

Datat som framställdes gjorde det möjligt att visualisera storleksskillnaden mellan kodbaserna såväl som vilka programmeringsspråk varje kodbas bestod av.

Nedan i Figur 8 visas formatet på det data som LOC producerar till en textfil, som vidare manipulerades med hjälp av reguljära uttryck i Notepad++, för att sedan föras över till ett Excel-dokument. Anledningen till detta var att förenkla hanteringen av data i Matlab.

Language	Files	Lines	Blank	Comment	Code
TypeScript	5100	598501	77716	101687	419098
JavaScript	458	175553	25750	29119	120684
Markdown	261	67580	23953	0	43627
JSON	456	18331	77	0	18254
HTML	495	13009	1576	1310	10123
CSS	199	7484	1071	180	6233
Sass	48	4507	714	129	3664
Bourne Shell	56	2240	427	420	1393
Plain Text	15	487	36	0	451
XML	2	16	0	0	16
Protobuf	1	51	9	27	15
Less	2	1	0	1	C
Total	7093	887760	131329	132873	623558

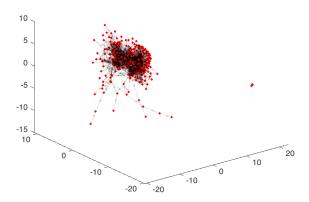
Figur 8: Texfilen som genererats med hjälp av LOC.

Vidare i Matlab lästes data från Excel-filerna in som tabeller med hjälp av funktionen readtable() för att på så sätt kunna använda det för visualiseringar. För att rita stapeldiagrammen i Matlab användes funktionen bar(), med transponatet av den inlästa tabellens rubriker som omvandlats till kategoriska data med hjälp av funktionen categorical() som x-värden. Tabellens numeriska kolumner utgjorde y-värden till stapeldiagrammet. För att tydliggöra vad varje stapel i diagrammet över ett ramverks beståndsdelar translaterar till för datamängd valde vi att använda färger av olika nyanser på staplarna, samt presentera en teckenförklaring för att visa vilket värde respektive färg motsvarar.

2.3 Riktade grafer

För att få fram data för kopplingar mellan klasserna i källkoden så användes JCallGraph, ett program med öppen källkod där man matar in en JAR-fil och får ut ett textdokument. Textfilen innehöll mer information än det som behövdes för denna uppgift så genom ett egenförfattat Java-program erhölls en textfil där varje rad representerade ett unikt anrop mellan två klasser. Det var då enkelt att läsa in filen i Matlab och deklarera start- och slut-noder och skapa en riktad graf.

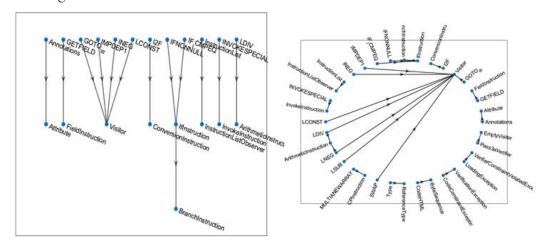
De första graferna gjordes i 3D då det ansågs vara ett bra sätt för att få se en översikt och kunna interagera med grafen (Figur 9). Det blev sedan tydligt att det var väldigt svårt att urskilja de olika klasserna (noderna) och vid försök till zoom så ändrades proportionerna på axlarna vilket gjorde att det var lätt att data hamnade utanför det visuella området.



Figur 9: Ett första försök till att skapa en visualisering över relationer mellan klasser med hjälp av en riktad graf.

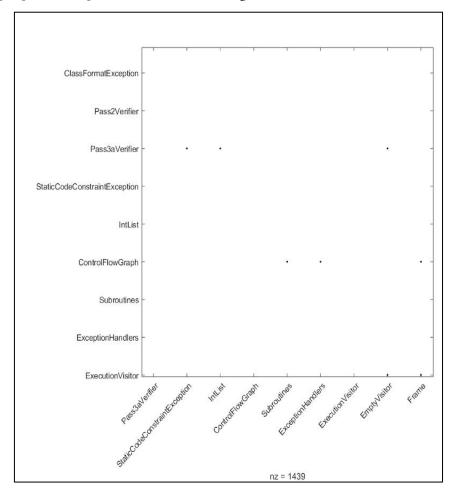
Då denna visualisering är över ett väldigt stort dataset ansågs en tvådimensionell representation av grafen vara mer tydlig. Detta trots att fler kantlinjer då nödvändigtvis korsar varandra. Forskning utförd av Helen Purchase visar att man bör sträva efter att ha så få kantlinjer som korsar varandra som möjligt för att öka förståelsen för det data som grafvisualiseringen ämnar förmedla [1].

Flera olika typer av grafer producerades genom att tillämpa olika grafritningsalgoritmer genom kommandot layout i Matlab, men med tanke på storleken så blev det många som blev alldeles för röriga för att kunna få någon information ut av den. Figur 10 visar exempel på olika layouts med bara en delmängd av datasetet.



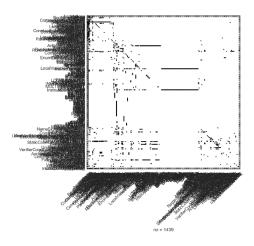
Figur 10: Två alternativa representationer av en riktad graf.

Vi försökte även visa kopplingarna med hjälp av en grannmatris, för att få en översiktlig bild över det hela, men även det blev väldigt rörigt. Figur 11 visar ett exempel på en anropsmatris med en delmängd av datasetet.

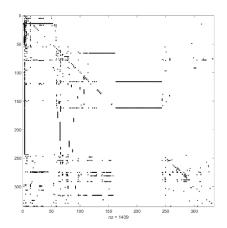


Figur 11: Grannmatris över en delmängd av datasetet.

Figur 12 visar en anropsmatris som innehåller hela datasetet. Visualiseringen är oläslig då alla klassnamnen är skrivna över varandra, men om man väljer att dölja klassnamnen som i Figur 13 så ser man kopplingarna men inte vilka som kopplar, och förlorar då en stor del av den information man vill kunna få ut av en källkods relationer.

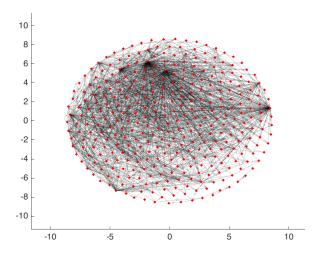


Figur 12: Grannmatris över hela datasetet med klassnamn längs x- och y-axlarna.



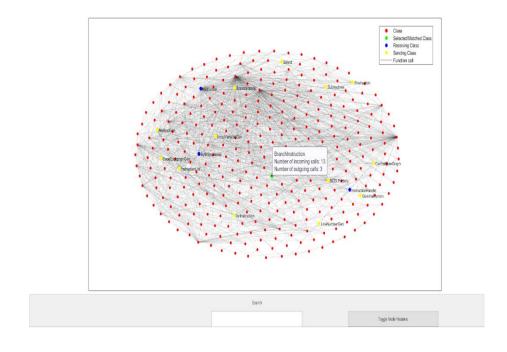
Figur 13: Grannmatris utan klassnamnen.

Trots att visualiseringen i Figur 14 nedan har många korsande kantlinjer ansågs den vara det bästa sättet att visa en stor mängd relationella data. Man ser lätt vilka klasser som har flest kopplingar, men relationernas riktningar går inte att utläsa. Vi valde att höja genomskinligheten i kantlinjerna något, då de nu blir en väldigt mörk figur och på flera ställen helsvart.



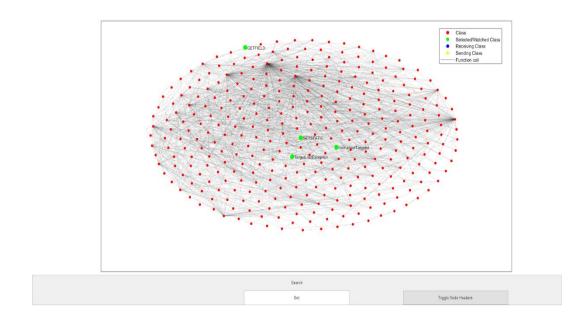
Figur 14: En lämplig visualisering av en anropsgraf.

Funktionalitet så som sökmetod samt markering av klasser som sedan visar upp dennes kopplingar implementerades även för en lättare hantering och interaktivitet. Det går att välja en nod (klass) och då kommer dess namn och alla dess kopplingar upp, deras namn samt om de är in eller utgående anrop (Figur 15).



Figur 15: En nod har klickats på. Inkommande och utgående anrop visas.

Det finns även en sökfunktion där alla klasser som innehåller sökordet markeras och klassnamnet visas (Figur 16). Värt att nämna är att sökfunktionen inte tar hänsyn till gemener och versaler, utan omvandlar både söksträngen och namnen på noderna (klasserna) till teckensträngar bestående av enbart gemener.



Figur 16: Programmets sökfunktion har använts med sökordet "get".

En grafs storlek är en viktig aspekt för hur tydlig visualiseringen av den är [2]. Genom att skapa ett interaktivt användargränssnitt där noder markeras på detta vis kan användaren fokusera på de delar av grafen som är relevanta.

Man kan även enkelt välja att visa alla klassers namn vilket även det är ett exempel på hur lätt det blir rörigt med ett stort dataset (Figur 17).



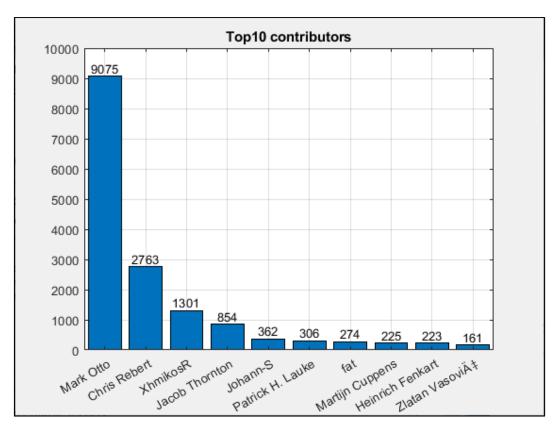
Figur 17: Alla klassnamn visas i grafen.

3 Resultat

3.1 Bidragshistorik till Git-repository

3.1.1 Diagram över de bidragsgivare som bidragit mest

Diagrammet som producerats visas i Figur 18.



Figur 18: Diagram över de bidragsgivare som bidragit mest.

Då domänen består av kategoriska data och kodomänen endast har en dimension (antalet bidrag) fanns få alternativ för val av visualisering. Ett alternativ hade varit att markera ut magnituden med punkter istället för staplar. Stapeldiagrammet valdes för att det ansågs vara tydligare.

3.1.2 Utskrift av antalet bidragsgivare, antalet bidrag och bidrag per bidragsgivare

I programmet skrivs antalet bidragsgivare, antalet bidrag och bidrag per bidragsgivare ut (Figur 19).

Number of contributors: 1276 Number of commits: 19057 Average commits per contributor: 14.935

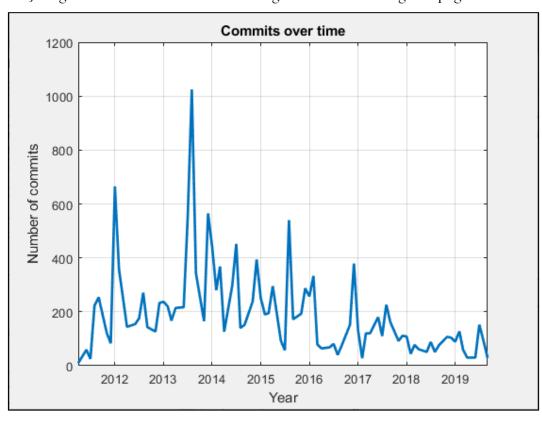
Figur 19: Utskrift av antalet bidragsgivare, antalet bidrag och bidrag per bidragsgivare.

Ett alternativ till att skriva ut medelvärdet (bidrag per bidragsgivare) hade varit att använda ett lådagram för att visa medianvärdet. Denna visualisering hade dock innehållit data utöver medianen (minimum, maximum, kvartilavstånd, etc.). Dessutom förmedlar medianvärdet och medelvärdet inte samma information. Dessa skillnader innebär att de två visualiseringarna är inte helt jämförbara.

En annan möjlig relaterad visualisering är cirkeldiagram för att visa hur stor del av bidragen som gjorts av vissa individer.

3.1.3 Visualisering av antalet bidrag över tid

För att visualisera antalet bidrag över tid användes ett linjediagram (Figur 20). Linjediagrammet var den enda visualiseringstekniken som ansågs lämplig.



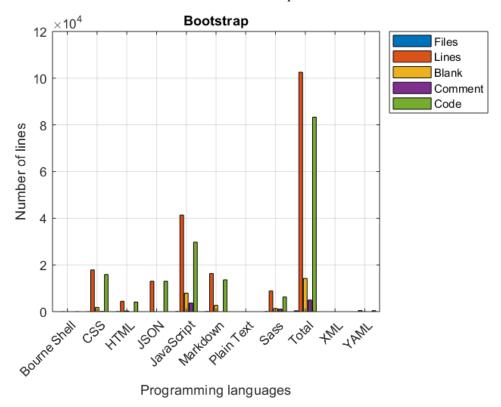
Figur 20: Linjediagram som visar antalet bidrag över tid.

3.2 Tillämpande av LOC på olika kodbaser

3.2.1 Diagram över ett ramverks beståndsdelar (Programmeringsspråk)

Ett av de framställda diagrammen visas i Figur 21. Längs x-axeln i har vi kategoriska data som anger vilket programmeringsspråk som det tillhörande värdet på y-axeln avser. Värt att notera är att "Total" inte är ett programmeringsspråk, utan en summering för den totala mängden av respektive kategori som finns i teckenförklaringen.

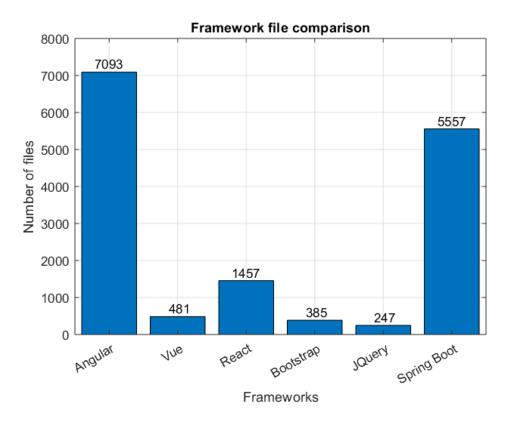
Som man ser i figuren så är storleken av en del datamängder betydligt mindre relativt de andra, detta leder till att det blir nästintill omöjligt att avläsa de mindre värdena på y-axeln. Under diskussionsdelen av denna rapport ges exempel på hur dessa mindre värden hade kunnat visualiserats på ett bättre sätt.



Figur 21: Diagram över vilka programmeringsspråk som har använts i källkoden.

3.2.2 Diagram över ramverkens beståndsdelar (Antal filer)

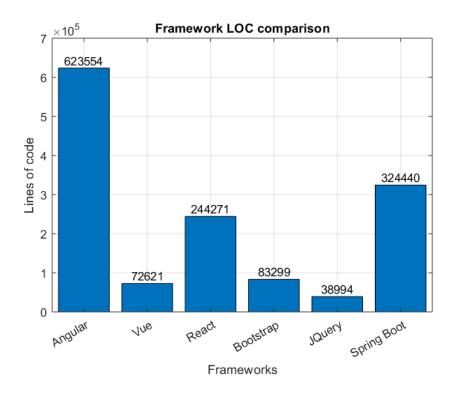
Nedan i Figur 22 har vi kategoriska data längs x-axeln som anger ramverket, längs y-axeln samt ovanför respektive stapel i diagrammet kan vi utläsa antalet filer som ramverket innehar.



Figur 22: Stapeldiagram som visar antalet filer i flera olika webbutvecklingsramverk.

3.2.3 Diagram över ramverkens beståndsdelar (Antal rader kod)

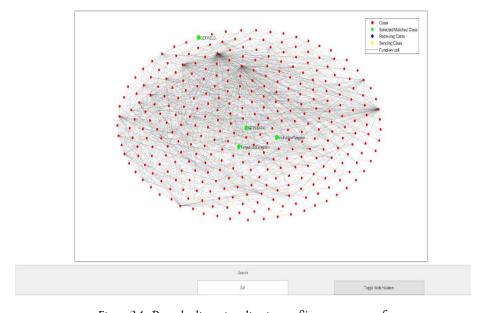
I Figur 23 har vi återigen kategoriska data längs-axeln som anger ramverket, längs y-axeln samt ovanför varje stapel i diagrammet kan vi utläsa antal rader av kod som ramverket består av.



Figur 23: Stapeldiagram som visar antalet rader kod i flera olika webbutvecklingsramverk.

3.3 Riktade grafer

Den visualisering vi ansåg bäst visade kopplingar mellan klasser är denna cirkel (Figur 24) i 2D som trots sina korsade linjer ger en bra översiktsbild och tillsammans med sök och markeringsfunktioner så är det lätt att hitta specifik information och se direkta och indirekta samband.



Figur 24: Den slutliga visualiseringen för en anropsgraf.

En anropsmatris kan vara ett kraftfullt verktyg för att snabbt se hur många och vilka kopplingar som finns, men tyvärr ej en passande visualisering för detta projekt. Något som kan diskuteras är att dela upp klasserna i olika grupper och visualisera de för sig men det kan då vara lätt att förlora förståelsen för helheten.

4 Diskussion

4.1 Bidragshistorik till Git-repository

Arbetet resulterade i en tydlig och överskådlig visualisering av bidragshistoriken. Programmet hade kunnat designats för att vara dynamiskt, så att det kan användas för att visualisera bidragshistorik från vilket Git-repository som helst. För att programmet ska fungera krävs att textfilen som genererats med Git Bash manipuleras manuellt innan inläsning till Matlab sker. Matlab-koden skulle också behöva utökas så att x-axeln (tiden) i linjediagrammet anpassas dynamiskt efter det dataset som används. Om källkod som har utvecklats i mindre än ett år hade det varit lämpligt att visa antalet bidrag per månad eller kanske till och med per dag.

4.2 Tillämpande av LOC på olika kodbaser

För de kodbaser som består av flera olika programmeringsspråk, och att storleken av ingående språken har stor differens finns det stor förbättringspotential. Den intuitiva avläsning av diagrammet blir näst intill omöjlig då diagrammets staplar har stor variation i deras värden. Ett bra alternativ för att bibehålla en intuitiv avläsning av diagrammet, är att separera mycket stora och små värden i olika diagram.

Ett annat alternativ vore att kompensera med någon form av interaktivitet, till exempel zoomning eller visning av stapelns värde när man håller muspekaren över den.

4.3 Riktade grafer

Det är ett stort problem att få en tydlig visualisering på kopplingar mellan en stor mängd klasser, men med hjälp av funktioner som gör att användaren kan söka på specifika klasser och se antal in- och utanrop samt se vilka klasser som den kopplar till gör det till en bra visualisering.

5 Referenser

- [1] H. Purchase, "Which Aesthetic Has the Greatest Effect on Human Understanding?," presented at the 5th International Symposium on Graph Drawing, Rome, Italy, Sep. 28-20 1997, pp. 248–261.
- [2] I. Herman, G. Melançon, and M. S. Marshall, "Graph visualization and navigation in information visualization: a survey," *IEEE Trans. Vis. Comput. Graph.*, vol. 6, no. 1, pp. 24–43, 2000.